Inteligencia Artificial 2027-I
Tarea 4

Posgrado en Ciencias e Ingeniería de la Computación, UNAM

12 de octubre de 2026

La implementación puede hacerse en cualquier lenguaje. Las bibliotecas de redes bayesianas, como `pgmpy` o `bnlearn`, solo pueden usarse para verificar los resultados. Los archivos de datos se describen al final del documento. Entregar el código, la salida y un reporte con las respuestas.

1. (25 puntos) Leer los siguientes dos artículos.

   - Zheng, X., Aragam, B., Ravikumar, P., & Xing, E. P. (2018). DAGs with NO TEARS: Continuous Optimization for Structure Learning. En *Advances in Neural Information Processing Systems 31* (NeurIPS 2018). arXiv:1803.01422. DOI: 10.48550/arXiv.1803.01422
   - Jin, Z., Chen, Y., Leeb, F., Gresele, L., et al. (2023). CLadder: Assessing Causal Reasoning in Language Models. En *Advances in Neural Information Processing Systems 36* (NeurIPS 2023). arXiv:2312.04350. DOI: 10.48550/arXiv.2312.04350

   a) (8 puntos) Escribir una crítica de cada uno de los dos artículos.

   b) (17 puntos) Responder las siguientes preguntas.

      1) (6 puntos) NO TEARS reemplaza la restricción combinatoria de aciclicidad por la ecuación $h(W) = \operatorname{tr}\big(e^{W \circ W}\big) - d = 0$. Explicar por qué $h(W) = 0$ si y solo si el grafo de W es acíclico. Comparar este enfoque con la búsqueda local sobre grafos del inciso 2(c) e indicar qué se gana y qué garantía se pierde.

      2) (5 puntos) NO TEARS supone variables continuas y un modelo lineal, y ajusta W con pérdida de mínimos cuadrados. Discutir si el método se aplica directamente a los datos discretos de CHILD y qué parte del método habría que cambiar.

      3) (6 puntos) Describir los tres niveles de la escalera causal que usa CLadder. Indicar qué nivel contesta una red bayesiana aprendida solo con datos observacionales, sin supuestos causales adicionales, y qué falta para contestar los otros dos.

2. (50 puntos) Implementación. Todos los incisos usan la red CHILD (`child.bif`), salvo que se indique otra.

   a) (8 puntos) d-separación.

      1) (5 puntos) Implementar un algoritmo que decida si la estructura de la red implica $X \perp\!\!\!\perp Y \mid \mathbf{Z}$, es decir, si X y Y están d-separadas dado $\mathbf{Z}$. Responder las siguientes consultas. Cuando la respuesta sea negativa, mostrar un camino activo.

(1) DuctFlow ⫫ CardiacMixing | Disease

(2) DuctFlow ⫫ CardiacMixing | Disease, LowerBodyO2

(3) Age ⫫ Grunting | Disease

(4) Age ⫫ Grunting | Disease, Sick

(5) HypDistrib ⫫ LungFlow | CardiacMixing, ChestXray

2) (3 puntos) La red `tratamiento.bif` tiene tres variables binarias y los arcos `Tratamiento`→`EfectoAdverso`, `EfectoAdverso`→`Recuperacion` y `Tratamiento`→`Recuperacion`. Calcular $P(\texttt{Recuperacion} \mid \texttt{Tratamiento})$ para ambos valores de `Tratamiento`. Decidir si `Tratamiento` y `Recuperacion` están d-separadas y si son independientes. Explicar la discrepancia.

b) (17 puntos) Inferencia.

1) (8 puntos) Implementar inferencia exacta por eliminación de variables. Antes de inferir, podar las variables que no son ancestros de la consulta ni de la evidencia. Calcular las siguientes distribuciones. Reportar la distribución, $P(\mathbf{e})$, el orden de eliminación usado, el número de entradas del factor intermedio más grande y el tiempo de ejecución.

(Q1) $P(\texttt{Disease} \mid \texttt{LVHreport} = \texttt{yes})$.

(Q2) $P(\texttt{Disease} \mid \mathbf{e})$, con $\mathbf{e}$ formada por `CO2Report`=`>=7.5`, `XrayReport`=`Plethoric` y `GruntingReport`=`yes`.

(Q3) $P(\texttt{Disease} \mid \mathbf{e})$, con $\mathbf{e}$ formada por `LowerBodyO2`=`<5`, `RUQO2`=`12+`, `LVHreport`=`yes` y `Age`=`0-3_days`.

(Q4) $P(\texttt{BirthAsphyxia} \mid \mathbf{e})$, con $\mathbf{e}$ formada por `CO2Report`=`>=7.5`, `XrayReport`=`Asy/Patchy`, `GruntingReport`=`yes`, `LowerBodyO2`=`<5`, `RUQO2`=`<5`, `LVHreport`=`no` y `Age`=`0-3_days`.

2) (5 puntos) Implementar muestreo por rechazo y ponderación por verosimilitud. Para Q3, graficar el error máximo absoluto respecto a la distribución exacta en función del número de muestras $N \in \{10^2, 10^3, 10^4, 10^5\}$. Promediar al menos 5 repeticiones. Reportar cuántas muestras acepta el muestreo por rechazo.

3) (4 puntos) Repetir el inciso anterior para $P(\texttt{Disease} \mid \mathbf{e})$, con $\mathbf{e}$ formada por `CO2Report`=`>=7.5`, `XrayReport`=`Oligaemic`, `GruntingReport`=`yes`, `LowerBodyO2`=`12+`, `RUQO2`=`<5`, `LVHreport`=`yes` y `Age`=`11-30_days`. Calcular $P(\mathbf{e})$ de forma exacta. Para la ponderación por verosimilitud, reportar el tamaño efectivo de muestra $N_{\text{ef}} = (\sum_i w_i)^2 / \sum_i w_i^2$. Explicar el comportamiento de cada método.

c) (25 puntos) Aprendizaje a partir de datos. Los archivos `child_datos_100.csv`, `child_datos_1000.csv` y `child_datos_10000.csv` contienen muestras independientes de la red CHILD. El archivo `child_prueba.csv` contiene 5 000 muestras adicionales para evaluar.

1) (5 puntos) Con la estructura verdadera, estimar los parámetros para cada tamaño de muestra por máxima verosimilitud y con suavizado de Laplace, que suma 1 a cada conteo. Reportar la log-verosimilitud de `child_prueba.csv` en cada caso y con los parámetros verdaderos. Explicar los resultados.

2) (10 puntos) Implementar búsqueda local sobre DAG con puntaje BIC. La búsqueda inicia en el grafo vacío y usa los operadores agregar, quitar e invertir arco, con verificación de aciclicidad. Para cada tamaño de muestra, reportar:

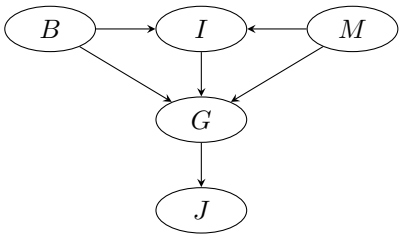
   - el número de arcos aprendidos
   - los arcos que faltan y los que sobran respecto a la red verdadera
   - la distancia de Hamming estructural (SHD) entre ambos DAG, es decir, el número de aristas que faltan, sobran o tienen otra dirección
   - el BIC de la red aprendida y el de la red verdadera sobre los mismos datos

3) (5 puntos) Invertir el arco `BirthAsphyxia`→`Disease` de la red verdadera y comparar el BIC de ambos DAG con $N = 1000$. Explicar por qué coinciden, por qué el SHD entre DAG es una medida engañosa del error de aprendizaje y qué implica el resultado para la interpretación causal de la red aprendida.

4) (5 puntos) Aplicar el mismo algoritmo a `sachs.csv`, que contiene datos reales de citometría de flujo. Comparar el resultado con la red de referencia de `sachs_referencia.txt` en aristas correctas, faltantes y sobrantes, y en orientación. Comparar el BIC de ambas redes. Discutir por qué el resultado es peor que con CHILD, aunque la red es más pequeña.

3. (25 puntos) Ejercicios del libro de Russell y Norvig, *Artificial Intelligence: A Modern Approach*, 3a. edición.

   a) (6 puntos) Ejercicio 14.14. Considerar la siguiente red con variables booleanas B = viola la ley electoral, I = es acusado, M = el fiscal tiene motivación política, G = es declarado culpable y J = va a la cárcel.



$$P(b) = 0.9, \quad P(m) = 0.1, \quad P(j \mid g) = 0.9, \quad P(j \mid \neg g) = 0$$
$$P(i \mid B, M): \ tt\text{: } 0.9, \ tf\text{: } 0.5, \ ft\text{: } 0.5, \ ff\text{: } 0.1$$
$$P(g \mid B, I, M): \ ttt\text{: } 0.9, \ ttf\text{: } 0.8, \ ftt\text{: } 0.2, \ ftf\text{: } 0.1, \ 0 \text{ si } I \text{ es falso}$$

   (a) ¿Cuáles de las siguientes afirmaciones implica la estructura de la red? (i) $P(B, I, M) = P(B)P(I)P(M)$. (ii) $P(J \mid G) = P(J \mid G, I)$. (iii) $P(M \mid G, B, I) = P(M \mid G, B, I, J)$.

   (b) Calcular $P(b, i, \neg m, g, j)$.

   (c) Calcular la probabilidad de ir a la cárcel dado que se violó la ley, hubo acusación y el fiscal tiene motivación política.

   (d) Una independencia específica de contexto permite que una variable sea independiente de algunos de sus padres para ciertos valores de los otros. Además de las independencias que da la estructura, ¿qué independencias específicas de contexto existen en esta red?

(e) Se quiere agregar la variable P = indulto presidencial. Dibujar la nueva red y justificar los arcos agregados.

b) (6 puntos) Ejercicio 14.15, incisos (c) y (d).

(c) Considerar una cadena de variables booleanas $X_1, \ldots, X_n$ con $Padres(X_i) = \{X_{i-1}\}$ para $i = 2, \ldots, n$. ¿Cuál es la complejidad de calcular $P(X_1 \mid X_n = \text{verdadero})$ sumando directamente sobre la distribución conjunta? ¿Y por eliminación de variables?

(d) Demostrar que la complejidad de eliminación de variables en un poliárbol es lineal en el tamaño de la red, para cualquier orden de eliminación consistente con la estructura de la red.

c) (7 puntos) Ejercicio 14.16.

(a) Demostrar que cualquier instancia de 3-SAT se reduce a inferencia exacta en una red bayesiana construida para representarla y, por lo tanto, que la inferencia exacta es NP-difícil. Como sugerencia, considerar una variable por símbolo proposicional, una por cláusula y una para la conjunción de las cláusulas.

(b) Contar el número de asignaciones que satisfacen una instancia de 3-SAT es #P-completo. Demostrar que la inferencia exacta es al menos así de difícil.

d) (6 puntos) Ejercicio 20.8. Considerar una red bayesiana arbitraria, un conjunto de datos completo para la red y la verosimilitud de los datos según la red. Demostrar que la verosimilitud no puede disminuir si se agrega un arco a la red y se recalculan los parámetros de máxima verosimilitud. Relacionar el resultado con el término de penalización del BIC del inciso 2(c).

Nota sobre los archivos

- `child.bif`. Red CHILD (Spiegelhalter y Cowell, 1992), un sistema experto para diagnosticar cardiopatías congénitas en recién nacidos, con 20 variables discretas y 25 arcos. La variable central es `Disease`, con seis diagnósticos. Las variables con sufijo `Report` son lecturas observables de los síntomas. El archivo `tratamiento.bif` usa el mismo formato BIF.
- `child_datos_*.csv` y `child_prueba.csv`. Una muestra por renglón y una variable por columna, con los nombres de los estados.
- `sachs.csv`. Contiene 853 mediciones de 11 proteínas y fosfolípidos en células T humanas (Sachs et al., 2005, *Science* 308:523–529), discretizadas en los niveles `BAJO`, `MEDIO` y `ALTO`. El archivo `sachs_referencia.txt` lista los 17 arcos de la red de consenso, uno por renglón.